

**UNIVERSIDAD NACIONAL
TORIBIO RODRÍGUEZ DE MENDOZA DE AMAZONAS**



ESCUELA DE POSGRADO

**TESIS PARA OBTENER EL GRADO ACADÉMICO DE MAESTRA EN
CAMBIO CLIMÁTICO, AGRICULTURA Y DESARROLLO RURAL
SOSTENIBLE**

**APLICACIÓN DE TÉCNICAS DE MACHINE LEARNING
PARA LA DETECCIÓN AUTÓNOMA Y EFICIENTE DE
MALEZAS EN CULTIVOS DE MAÍZ, 2023**

Autora:

Bach. Meliza del Pilar Bustos Chavez

Asesor:

Dr. Jonathan Alberto Campos Trigoso

Registro: (...)

CHACHAPOYAS – PERÚ

2025

Autoridades de la Universidad Nacional Toribio Rodríguez de Mendoza de Amazonas

Jorge Luis Maicelo Quintana Ph.D.

Rector

Dr. Oscar Andrés Gamarra Torres

Vicerrector académico

Dra. María Nelly Luján Espinoza

Vicerrectora de investigación

Dr. Efraín Manuelito Castro Alayo

Director de la Escuela de Posgrado

Jurado evaluador de la tesis



Dr. Nilton Luis Murga Valderrama

Presidente



Dr. Héctor Vladimir Vásquez Pérez

Miembro



Mg. Cesar Rafael Balcázar Zumaeta

Miembro

Constancia de originalidad de la tesis



ANEXO N° 4 CONSTANCIA DE ORIGINALIDAD²

Los suscritos, miembros del Jurado Evaluador del Proyecto de Tesis (), Tesis (X), Tesis en formato de artículo científico () titulado:

Aplicación de técnicas de machine learning para la detección autónoma y eficiente de malezas en cultivos de maíz, 2023

presentado por el Aspirante
Meliza del Pilar Bustos Chavez para obtener el Grado

Académico de Maestro (X)/Doctor () en
Cambio Climático, Agricultura y Desarrollo Rural Sostenible

de la Escuela de Posgrado de la UNTRM, hacemos constar que después de revisar la originalidad del Proyecto de Tesis (), Tesis (X), Tesis en formato de artículo científico () con el software de prevención de plagio **Turnitin**, verificamos:

- De acuerdo con el informe de originalidad, el Proyecto de Tesis (), Tesis (X), Tesis en formato de artículo científico () tiene 8 % de similitud, que es menor al 25% permitido en la UNTRM.
- La persona responsable de someter el Proyecto de Tesis (), Tesis (X), Tesis en formato de artículo científico () al software de prevención de plagio **Turnitin** fue:
Dr. Nilton Luis Murga Valderrama y pertenece al área ()/oficina ()/dependencia (X) de Facultad de Ingeniería Zootecnista, Biotecnología, Agronegocios y Ciencia de Datos.

SE ADJUNTA:

- Resultado del informe del software **Turnitin**.

Chachapoyas, 24 de setiembre del 2025

PRESIDENTE

Nombres y apellidos:
Dr. Nilton Luis Murga Valderrama
DNI: 33430926

MIEMBRO

Nombres y apellidos:
Dr. Héctor Vladimir Vasquez Pérez
DNI: 26723685

MIEMBRO

Nombres y apellidos:
Mg. César Rafael Balcázar Zumaeta
DNI: 46734552

OBSERVACIONES:

² Marcar según corresponda la etapa y modalidad del proceso de graduación, pudiendo ser: Proyecto de Tesis, Tesis o Tesis en formato de artículo científico.

Reporte de turnitin

APLICACIÓN DE TÉCNICAS DE MACHINE LEARNING PARA LA DETECCIÓN AUTÓNOMA Y EFICIENTE DE MALEZAS EN CULTIVOS DE MAIZ, 2023

INFORME DE ORIGINALIDAD

8%	8%	4%	%
INDICE DE SIMILITUD	FUENTES DE INTERNET	PUBLICACIONES	TRABAJOS DEL ESTUDIANTE

FUENTES PRIMARIAS

1	hdl.handle.net Fuente de Internet	2%
2	revistas.ulcb.edu.pe Fuente de Internet	1%
3	repositorio.chapingo.edu.mx Fuente de Internet	1%
4	repositorio.utn.edu.ec Fuente de Internet	<1%
5	ouci.dntb.gov.ua Fuente de Internet	<1%
6	www.mdpi.com Fuente de Internet	<1%
7	Yanyun Wang, Jiarui Cui, Jie Hao, Fujia Dong, Hailong Xu, Yingjie Feng, Changhao Li, Shenghui Ma, Songlei Wang. "Deep learning-enhanced near-infrared hyperspectral imaging with hybrid attention for rapid detection of caspase-3 activity in postmortem tan lamb", Microchemical Journal, 2025 Publicación	<1%
8	aprenderly.com Fuente de Internet	<1%
9	www.frontiersin.org Fuente de Internet	<1%

Nilton L. Murga
33430926

Acta de sustentación de la tesis



UNTRM

REGlamento DEL PROCESO DE GRADUACIÓN
PARA EL OTORGAMIENTO DEL GRADO ACADÉMICO
DE MAESTRO / DOCTOR
R.C.U N° 0259-2025

ANEXO N° 6 ACTA DE SUSTENTACIÓN DE TESIS

En el Auditorio de la Escuela de Posgrado de la UNTRM - Chachapoyas, el día 17 de OCTUBRE del año 2025, siendo las 3:00pm horas, el Aspirante IRELIZA DEL PILAR BUSTOS CHAVEZ, cuyo asesor es DR. JONATHAN ALBERTO CAMPOS TRIGOSO, defiende en sesión pública presencial la Tesis titulada:

"APLICACIÓN DE TÉCNICAS DE MACHINE LEARNING PARA LA DETECCIÓN AUTÓNOMA Y EFICIENTE DE PLAGAS EN CULTIVOS DE MAÍZ, 2023"

para obtener el Grado Académico de Maestro (X) / Doctor ()

en CAMBIO CLIMÁTICO, AGRICULTURA Y DESARROLLO RURAL SOSTENIBLE (MACCARRD), a ser otorgado por la Universidad Nacional Toribio Rodríguez de Mendoza de Amazonas; ante el Jurado Evaluador, conformado por:

Presidente: NILTON LUIS PUJANA VALDEERRAMA

Secretario: HECTOR WASHINGTON VÁSQUEZ PÉREZ

Vocal: CÉSAR RAFAEL BALCÁZAR ZURBETA

Luego de la sustentación y absueltas las preguntas del Jurado Evaluador se procedió a la calificación individual y secreta, teniendo el resultado de:

Aprobada (X) / Desaprobada () por Unanimidad (X) / Mayoría ().

Otorgada la calificación, el Secretario del Jurado Evaluador lee la presente Acta en esta misma sesión pública. A continuación, se levanta la sesión. Siendo las 4:05pm horas del mismo día y fecha, el Jurado Evaluador concluye el acto de sustentación de la Tesis.




PRESIDENTE
Nombres y apellidos:
NILTON LUIS PUJANA
VALDEERRAMA
DNI: 33430926


MIEMBRO
Nombres y apellidos:
HECTOR WASHINGTON
VÁSQUEZ PÉREZ
DNI: 26723685


MIEMBRO
Nombres y apellidos:
CÉSAR RAFAEL
BALCÁZAR ZURBETA
DNI: 46734552


ASESOR
Nombres y apellidos:
JONATHAN ALBERTO
CAMPOS TRIGOSO
DNI: 45861852

Índice general

Autoridades de la Universidad Nacional Toribio Rodríguez de Mendoza de Amazonas	ii
Jurado evaluador de la tesis	iii
Constancia de originalidad de la tesis	iv
Reporte de turnitin	v
Acta de sustentación de la tesis	vi
Índice general	vii
Índice de tablas	ix
Índice de figuras	x
Resumen	xi
Abstract	xii
I. INTRODUCCIÓN	13
II. MATERIAL Y METODOS	17
2.1 Proceso metodológico	17
2.2 Fuente y composición de los datos	17
2.2.1 Datos públicos	17
2.2.2 Conjunto independiente de datos	18
2.3 Preprocesamiento de imágenes	19
2.4 Procesamiento, entrenamiento y evaluación	19
2.4.1 Estrategia de evaluación y selección de modelos YOLO	20
2.4.2 Métodos de detección basados en aprendizaje profundo	21
2.4.2.1 Métodos de detección e identificación basado en YOLOv11	22
2.4.2.2 Métodos de detección e identificación basado en YOLOv8	23
2.4.2.3 Métodos de detección e identificación basado en YOLOv5u	24
2.4.3 Métricas de evaluación	26
2.4.3.1 Precisión (precision)	26
2.4.3.2 Recuperación (recall)	26

2.4.3.3	F1- Score	27
2.4.3.4	Precisión promedio media (mAP, mean Average Precision)	27
III.	RESULTADOS	28
3.1	YOLOv5u	28
3.1.1	Análisis de métricas y costo computacional	28
3.1.2	Inspección visual de la predicción del modelo YOLOv5u	30
3.2	YOLOv8	31
3.2.1	Análisis de métricas y costo computacional	31
3.2.3	Inspección visual de la predicción del modelo YOLOv8	32
3.3	YOLOv11	33
3.3.1	Análisis de métricas y latencia de inferencia	33
3.3.2	Inspección visual de la predicción del modelo YOLOV11	35
3.4	Comparación y selección de deep learning	36
3.5	Determinación del modelo final y caracterización de YOLOv8x	38
3.5.1	Verificación en campo	40
IV.	DISCUSIÓN	42
V.	CONCLUSIONES	45
VI.	RECOMENDACIONES	46
VII.	REFERENCIAS BIBLIOGRÁFICAS	47

Índice de tablas

Tabla 1 Métricas del modelo YOLOv5u	29
Tabla 2 Métricas del modelo YOLOv8	32
Tabla 3 Métricas de YOLOv11	35

Índice de figuras

Figura 1	Diagrama del flujo de datos y evaluación de modelos	17
Figura 2	Distribución del dataset	18
Figura 3	Proceso de entrenamiento de modelos YOLO bajo la plataforma Ultralytics	20
Figura 4	Esquema de evaluación de modelos y elección del mejor desempeño	21
Figura 5	Inferencia de los modelos YOLOv5u aplicados a maize y weed	30
Figura 6	Inferencia de los modelos YOLOv8 aplicados a maize y weed	33
Figura 7	Inferencia de los modelos YOLOv11 aplicados a maize y weed	36
Figura 8	Precisión, recall y F1 Score por familia Yolo	37
Figura 9	Rendimiento y latencia en familias YOLO	38
Figura 10	Curvas de entrenamiento y validación de YOLOv8x	39
Figura 11	Matriz de confusión normalizada	40
Figura 12	Evaluación por umbral: F1 y Precisión - Recall de YOLOv8x	40
Figura 13	Evaluación visual del modelo YOLOv8x	41

Resumen

La visión artificial es un pilar de la inteligencia artificial, capacita a las máquinas para analizar e interpretar imágenes permitiendo la identificación precisa de objetos; el objetivo de la presente investigación fue detectar y localizar malezas en cultivos de maíz empleando modelos basados en deep learning, para ello, se utilizó un dataset público de imágenes anotadas con dos clases: maíz y malezas; se entrenó de forma homogénea las variantes n, s, m, l y x de las familias YOLOv5u, YOLOv8 y YOLOv11; y se evaluó con las métricas de precisión, recall, F1, mAP 0.50 y mAP 0.50 y 0.95, el tiempo de entrenamiento y latencia por imagen, todos los modelos fueron ajustados en pesos base y se compararon sobre el mismo conjunto de evaluación. Los resultados mostraron que YOLOv8x alcanzó el mejor equilibrio entre sensibilidad y localización, con un recall de 0.698, F1 de 0.818, mAP@50 de 0.844 y mAP@50:95 de 0.752, superando a YOLOv5xu (F1 0.790; mAP@50:95 0.729) y a YOLOv11x (F1 0.754; mAP@50:95 0.705); en cuanto a las clases, la clase maíz mostró un desempeño alto y estable en todas las familias, y las malezas fue el factor limitante por la presencia de objetos pequeños y ocluidos, el costo computacional creció con la capacidad del modelo. En conclusión, principal fue adoptar YOLOv8x por su mayor sensibilidad y mejor mAP multiumbral y la validación con imágenes propias de campo, esto confirmó una buena adaptación al dominio, lo que justifica aceptar su mayor latencia.

Palabras claves: Detección de objetos, Maíz, Malezas, Agricultura de precisión

Abstract

Artificial vision is a pillar of artificial intelligence, enabling machines to analyze and interpret images, allowing for the accurate identification of objects. The objective of this research was to detect and locate weeds in corn crops using deep learning-based models. To do this, a public dataset of images annotated with two classes was used: corn and weeds. The n, s, m, l, and x variants of the YOLOv5u, YOLOv8, and YOLOv11 families were trained homogeneously and evaluated using the metrics of precision, recall, F1, mAP 0.50, and mAP 0.50 and 0.95, training time, and latency per image. All models were adjusted in base weights and compared on the same evaluation set. The results showed that YOLOv8x achieved the best balance between sensitivity and localization, with a recall of 0.698, F1 of 0.818, mAP@50 of 0.844, and mAP@50:95 of 0.752, outperforming YOLOv5xu (F1 0.790; mAP@50:95 0.729) and YOLOv11x (F1 0.754; mAP@50:95 0.705); in terms of classes, the corn class showed high and stable performance in all families, and weeds were the limiting factor due to the presence of small and occluded objects; the computational cost increased with the capacity of the model. The main conclusion was to adopt YOLOv8x due to its greater sensitivity and better multi-threshold mAP, and validation with our own field images confirmed good adaptation to the domain, which justifies accepting its higher latency.

Keywords: Object detection, Maize, Weed, Precision agriculture

I. INTRODUCCIÓN

Se prevé que para el 2050, la población mundial alcanzará aproximadamente los 9800 millones de personas, mostrando un aumento significativo con respecto a los 7800 millones registrados a fines del 2021, las estimaciones indican un aumento de alrededor de 2500 millones de personas entre el 2015 y 2050 (Munkhbat et al., 2022; Price, 2022). El aumento de la población mundial plantea un desafío para la producción mundial de alimentos, para albergar este desafío la producción debe incrementar entre un 60 y 70% entre el 2025 y 2050 con prácticas de intensificación sostenible que mejoren el rendimiento de los cultivos (Rattan, 2016).

La agricultura enfrenta muchos desafíos, además de una producción más intensiva y la reducción de la tierra apta para el cultivo, el cambio climático impacta significativamente, los niveles elevados de CO_2 y los cambios de temperatura favorecen la competitividad de las malezas en los cultivos agrícolas (Kumar et al., 2023). Las malezas con su diversidad genética y adaptabilidad prosperan en condiciones climáticas alteradas, afectando directamente el rendimiento de los cultivos alimentarios y forrajeros e incrementando la dinámica de plagas y enfermedades (Mehraj et al., 2022).

Las malezas son plantas nativas que crecen de forma natural y compiten con los cultivos por recursos como la luz, el espacio y la humedad, provocando pérdidas de rendimiento si no son controladas adecuadamente. En cultivos destinados al consumo humano la pérdida potencial total mundial debido a las malezas es del 34% a diferencia de las plagas y patógenos que causan menos pérdidas en un 18% y 16% respectivamente (Oerke, 2006). El manejo de las malezas en la agricultura moderna evita pérdidas de rendimiento y garantiza la seguridad alimentaria tomando en cuenta las prácticas intensivas, el cambio climático y los desastres naturales que afectan su dinámica (Tursun et al., 2016).

Los agricultores optan por un manejo de malezas con técnicas químicas, mecánicas, biológicas, eléctricas y manuales que son laboriosas, convencionales y no dirigidas (Bajwa et al., 2015). El uso de maquinaria convencional puede no eliminar con precisión las malezas que se encuentran en las hileras de los cultivos y las aplicaciones generales de

herbicidas tienen efectos más adversos sobre el medio ambiente que las aplicaciones de herbicidas en sitios específicos (Young & Giles, 2014). Por estos motivos, se debe precisar el manejo de malezas en lugares específicos con técnicas de control precisas y efectivas en tiempo, costo y mano de obra (Ahmad et al., 2018).

Para lograr un manejo eficaz de malezas, estas deben ser previamente identificadas y clasificadas en sitios específicos del cultivo; esto es posible gracias a la clasificación de malezas basadas en imágenes y al uso de algoritmos de aprendizaje automático y de aprendizaje profundo (Behmann et al., 2015; Hasan et al., 2021a). A lo largo de los años, los algoritmos de aprendizaje automático y profundo han sido utilizados en diferentes dominios, como el reconocimiento de expresiones faciales, reconocimiento del habla (Shan et al., 2009), clasificación de cortes de carne (Sunil et al., 2021), identificación de cultivos y clasificación de plantas (Saini et al., 2020; Tufail et al., 2021), predicción del rendimiento de los cultivos (Nevavuori et al., 2019), clasificación de enfermedades de plantas (Mohanty et al., 2016) y con gran potencial para la clasificación de malezas (Hu et al., 2020; S. Khan et al., 2021).

Detectar malezas en cultivos agrícolas es un gran desafío ya que las malezas y las plantas cultivadas a menudo tienen colores, texturas y formas similares, es por lo que el paso inicial para desarrollar un sistema automático de gestión de malezas es detectarlas y reconocerlas correctamente (Liu & Bruch, 2020). Esto es posible gracias al avance de las tecnologías informáticas innovadoras respaldadas por la inteligencia artificial con el uso de aprendizaje automático y profundo (Yu et al., 2019). Un sistema de detección de malezas sigue cuatro etapas claves: adquisición de imágenes, extracción de características y detección y clasificación de malezas (Hasan et al., 2021b).

El maíz (*Zea mays*) es uno de los productos básicos más consumidos en el mundo, considerado como un cultivo altamente productivo por su amplia gama de usos industriales y agrícolas como alimentos para animales, biocombustibles y edulcorantes alimentarios (Venkataraju et al., 2023). Uno de los principales retos para lograr una mayor productividad del maíz es el control y manejo del crecimiento de malezas, ya que

compiten con el maíz por los nutrientes introduciendo bacterias dañinas, virus u otros microorganismos; en un estudio realizado por el Departamento de Agricultura de los Estados Unidos - Servicio Nacional de Estadísticas Agrícolas (USDA-NASS) determinó que la interferencia de las malezas en la producción de maíz resultó en una pérdida promedio de rendimiento del 50% anual entre 2007 y 2013 (Soltani et al., 2016).

En el Perú el maíz se siembra en las tres regiones naturales; Costa, Sierra y Selva, alrededor del 56% de la superficie nacional sembrada es maíz amarillo duro y maíz amiláceo, este cultivo tiene relevancia económica, social y estratégica ya que es el motor de desarrollo para alrededor de 8 millones de personas ubicadas en los estratos más pobres del país (García, 2017). El maíz amiláceo es considerado uno de los principales alimentos después de la papa, su producción es destinada al autoconsumo, el consumo promedio es aproximadamente 34,52 g/persona/día, principalmente se consume en forma de choclo, mote, harina precocida, bebidas, cancha y otros (AgroRural, 2019). A pesar de que el Perú ha venido mejorando sus niveles de productividad (3,3 tn/ha), los rendimientos promedios de maíz amiláceo en la Sierra continúan siendo bajos, en promedio no superan las 1,3 tn/ha, esto debido a la inadecuada selección de semillas, baja fertilidad de los suelos y deficientes labores agronómicas que no se adaptan a las recomendaciones técnicas establecidas para el cultivo (IICA, 2013).

Se han propuesto varios métodos para contar y clasificar plantas de maíz para mejorar la producción agrícola y el manejo de enfermedades; uno de los enfoques implica el uso de modelos de aprendizaje profundo como YOLOV5 para la detección y el recuento de plantas de maíz, logrando altas tasas de precisión y correlación con los recuentos manuales (Yang et al., 2022), otro método incorpora características contextuales conscientes de la escala e interdependencia de canales para un recuento eficaz de plantas de maíz, utilizando una función de pérdida híbrida para el entrenamiento (Yong-Yang et al., 2022), también se han empleado imágenes espectrales obtenidas por un Vehículo Aéreo no Tripulado (VANT), Transformada Circular de Hough y técnicas de aprendizaje automático como Máquinas de Soporte Vectorial (SVM) y Redes Neuronales (NN) para el recuento y la determinación de la altura de las plantas de maíz, mostrando la automatización y precisión

de la identificación de las plantas (Veramendi & Cruvinel, 2021), además, se ha abordado la clasificación de enfermedades de las plantas de maíz utilizando redes neuronales convolucionales (CNN) con diferentes arquitecturas como ResNet-18, VGG16 y EfficientNet, logrando altas precisiones a través de métodos de entrenamiento optimizados y abordando distribuciones de clases desequilibradas (Ahadian et al., 2023), por último, se ha explorado la clasificación de enfermedades del maíz utilizando métodos de Random Forest, Redes Neuronales y Naive Bayes, que han demostrado una precisión superior en la clasificación de conjuntos de datos de hojas de maíz (Ubaidillah et al., 2022).

Aun así, gran parte de estos aportes se centra en conteo o diagnóstico de enfermedades del cultivo, mientras que la detección y localización precisa de malezas en campo abierto sigue enfrentando retos por la pequeña escala de los objetivos (Costamagna et al., 2017); en este contexto, establecer una metodología reproducible de detección y localización de malezas tendría un impacto directo en el uso eficiente de herbicidas, es por eso que es necesario un sistema capaz de identificar dónde están las malezas y cuántas son, permitiendo tratar solo las zonas necesarias con dosis adecuadas, reducir insumos y priorizar las intervenciones según tiempo y recursos disponibles (López et al., 2020).


En extensas áreas agrícolas, el control eficiente de malezas optimiza recursos y maximiza la productividad, por tanto, esta investigación buscó detectar y localizar malezas en cultivos de maíz mediante técnicas de deep learning, con los objetivos de: i) comparar modelos de deep learning para lograr una detección autónoma y eficiente; ii) evaluar su desempeño mediante métricas de precisión, recall, F1 score y mAP, y por ultimo iii) emplear el modelo óptimo para realizar detecciones con imágenes propias de campo, validando su adaptabilidad al dominio.

esta nombrado como “Weed - Object Detection Dataset and Pre-Trained Model” y es atribuida al autor Detection (2022), en esta publicación no se consigna la procedencia geográfica de las imágenes, por lo que la ubicación de captura se considera no especificada y se cita la fuente oficial como referencia primaria.

La división de conjunto de imágenes comprende con un 70.7% (7,000) asignadas al conjunto de entrenamiento (Train), un 15.2% (1,500) al conjunto de validación (Valid) y un 14.1% (1,400) al conjunto de prueba (Test), y la muestra de la distribución de las instancias de objetos se dividió con un 70.0% (225,948) para entrenamiento, un 15.8% (51,049) para validación y un 14.2% (45,830) para prueba.

Figura 2

Figura 2 *Distribución del dataset*



2.2.2 Conjunto independiente de datos

Se incorporó un conjunto independiente con imágenes de sembríos de maíz del Centro Experimental San Juan de la Estación Experimental Agraria Amazonas (INIA), ubicado en el distrito de Chachapoyas, provincia de Chachapoyas, región Amazonas, a 2 347 msnm, con coordenadas 6°12'20.38'' S y 77°52'34.88'' O, durante el período de evaluación, según SENAMHI (2024), la temperatura máxima promedio mensual osciló entre 16,2 °C y 24,2 °C, la mínima entre 6,4 °C y 12,8 °C, la humedad relativa entre 66,7% y 92,5%, y la precipitación mensual entre 0,5 mm y 14,2 mm, el maíz correspondió a la variedad INIA 603 Choclero y las imágenes se capturaron 25 días después de la siembra, realizada el día sábado 02 de agosto del 2025.

2.3 Preprocesamiento de imágenes

Todas las imágenes se sometieron a Auto-Orient para corregir la orientación según metadatos y luego se redimensionaron por estiramiento a 640×640 píxeles, a continuación, se trabajó en RGB y los tensores de entrada se normalizaron al rango 0 - 1 durante el entrenamiento.

En el conjunto de entrenamiento se aplicaron aumentaciones controladas: volteo horizontal y vertical; conversión a escala de grises aplicada de forma aleatoria a 15% de las imágenes; variación de saturación entre -25% y +25%; variación de brillo entre -15% y +15%; y desenfoque de hasta 0.8 px. Los conjuntos de validación y prueba recibieron solo el preprocesado común (Auto-Orient y redimensionado a 640×640), sin aumentaciones. Se unificó el formato de anotaciones al esquema YOLO y se realizó un control de calidad sobre una muestra aleatoria del 10%, verificando ajuste de cajas, duplicados y coherencia de clase antes de iniciar el entrenamiento.


2.4 Procesamiento, entrenamiento y evaluación

Los modelos YOLOv5u, YOLOv8 y YOLOv11 se entrenaron con pesos preentrenados en un entorno estandarizado para asegurar comparabilidad: la ejecución se realizó en Ultralytics Hub mediante su interfaz gráfica, siguiendo el flujo operativo que consiste en acceder al módulo de modelos, iniciar el entrenamiento con Train Model, seleccionar el dataset, elegir la familia y el tamaño del modelo, configurar la receta común y exportar el código equivalente para reproducibilidad. *Figura 3*

La misma configuración avanzada se aplicó a todas las familias: 100 épocas, tamaño de imagen 640, paciencia 100 para detención temprana, tamaño de lote automático ajustado a la memoria disponible, estrategia de caché desactivada y dispositivo en modo automático; el entrenamiento se ejecutó sobre GPU NVIDIA L4 con CUDA, PyTorch 2.4.1 y Python 3.12, lo que mantuvo tiempos de cómputo consistentes y comparables entre modelos. Para cada familia se seleccionó el mejor checkpoint por su desempeño en validación medido con mAP 50 y mAP 50-95, velando porque no se degradará de forma relevante la clase Maize; la evaluación interna se efectuó sobre el 20% reservado para prueba y reportó mAP 50, mAP 50-95, precisión, exhaustividad y F1, además de latencia por imagen e imágenes por segundo con lote 1 para valorar la idoneidad operativa en campo y en dispositivos de borde.

El modelo seleccionado se probó con imágenes individuales del conjunto independiente mediante inferencia directa en condiciones reales, fijando tamaño 640, umbral de confianza 0.50 y umbral de IoU 0.50 coherentes con la validación; el sistema mostró cajas y etiquetas por clase junto con puntajes de confianza, lo que permitió revisar aciertos, errores y casos límite, empleando estas imágenes exclusivamente para inspección visual y para verificar la coherencia de las predicciones fuera del dominio de entrenamiento.

Figura 3 *Proceso de entrenamiento de modelos YOLO bajo la plataforma Ultralytics*




2.4.1 Estrategia de evaluación y selección de modelos YOLO

La selección del mejor detector se estableció mediante los protocolos de evaluación estandarizados y reproducibles descritos en la literatura, los indicadores de exactitud incluyeron Precision, Recall y F1, junto con Average Precision por clase y su promedio global (mAP) demostrando el compromiso precisión y exhaustividad mediante el área bajo la curva, permitiendo comparar métodos de forma consistente entre las clases (Gonçalves et al., 2024); diversas revisiones metodológicas documentan estas definiciones operativas y su uso en detección de objetos y sus variantes basadas en umbrales de superposición espacial (IoU) únicos o múltiples (Ilyas, 2024).

Además de la calidad de detección, se consideraron criterios de eficiencia como latencia por imagen y tiempo total de entrenamiento, puesto que se equilibró la exactitud, velocidad y uso de memoria para avalar viabilidad operativa en el entorno de despliegue. Por tanto, los modelos se compararon con un conjunto común de métricas: Precision, Recall, F1, mAP@50 y mAP@50–95 para exactitud, y tiempo de entrenamiento y velocidad de inferencia para eficiencia, y el modelo recomendado fue aquel que alcanzó el mayor mAP@50–95 sin sacrificar estabilidad de Precision y Recall, además mostró latencia compatible con los requisitos de uso en campo (L. Liu et al., 2020; Padilla et al., 2021). *Figura 4*

Figura 4 Esquema de evaluación de modelos y elección del mejor desempeño



2.4.2 Métodos de detección basados en aprendizaje profundo

La visión por computadora, una aplicación tecnológica avanzada de la agricultura de precisión permite tomar decisiones informadas con un método inteligente y eficiente para distinguir cultivos deseados y malezas indeseables mediante el detallado de imágenes; en este campo destacan dos metodologías: los enfoques tradicionales basados en características y los métodos de aprendizaje profundo (Elsayed et al., 2024).

Los métodos tradicionales basados en características requieren de identificación manual de atributos específicos en una imagen para realizar la clasificación, mientras

que el aprendizaje profundo entrena modelos complejos de redes neuronales utilizando grandes conjuntos de datos de imágenes etiquetadas, a través de procesos de aprendizaje iterativo, la Red Neuronal Convulsional (CNN) extrae automáticamente características relevantes y realiza clasificadores basadas en las imágenes de entrada (Moldvai et al., 2024).

2.4.2.1 Métodos de detección e identificación basado en YOLOv11

YOLOv11 representa la versión más reciente de la familia de algoritmos YOLO (You Only Look Once), se caracteriza por su equilibrio entre velocidad, precisión y eficiencia computacional, introduce mejoras significativas en la extracción de características mediante una arquitectura optimizada de columna vertebral y cuello, incluyendo los bloques C3k2 (una capa convolucional con filtros de tamaño 3x3), SPPF (Spatial Pyramid Pooling - Fast) y C2PSA (Bloque convolucional con atención espacial paralela), los cuales potencian la capacidad del modelo para identificar objetos con mayor robustez, con variantes escalables como: YOLOv11n, YOLOv11s, YOLOv11m, YOLOv11l y YOLOv11x, adaptadas a distintos escenarios de aplicación (Sharma et al., 2024; Ultralytics, 2024).

En el proceso de detección, inicialmente la imagen de entrada es sometida a un preprocesamiento, donde se redimensiona a un tamaño fijo, para garantizar la compatibilidad con la red neuronal convolucional y mantener la relación de aspecto dentro de parámetros adecuados para la detección de objetos. A continuación, se realiza la extracción de características mediante Darknet53, una red neuronal convolucional optimizada que emplea capas convolucionales junto a técnicas de normalización por lotes (batch normalization), esta arquitectura permite capturar información de distintos niveles, combinando características de bajo y alto nivel sin comprometer la eficiencia computacional. Posteriormente, la imagen procesada se divide en una malla de cuadrículas de tamaño $S \times S$, donde cada celda es responsable de predecir B cuadros delimitadores, los que van a contener la información detallada sobre los objetos detectados, incluyendo (i) las coordenadas del centro del cuadro delimitador (x, y), (ii) su ancho y alto (w, h), y (iii) un puntaje de confianza,

que representa la probabilidad de que el cuadro contenga efectivamente un objeto; además para mejorar la precisión de la detección, el modelo aplica un mecanismo de supresión de valores no extremadamente grandes (Non-Maximum Suppression, NMS), cuyo objetivo es eliminar cuadros redundantes con alta superposición, este proceso se basa en la comparación del grado de solapamiento y la confianza de predicción, asegurando que solo se conserven los cuadros con mayor relevancia. Finalmente, los resultados obtenidos pasan por una etapa de filtrado, en la que se descartan detecciones con confianza inferior a un umbral predefinido, de esta manera, el modelo genera una representación final optimizada de los objetos detectados, proporcionando información precisa sobre su ubicación dentro de la imagen y su probabilidad de pertenecer a una categoría específica (Hussain, 2023; Wang et al., 2025). Este diseño aprovecha mapas de características compartidos, reduciendo la redundancia computacional y optimizando la inferencia en tiempo real, además, incorpora anclas predefinidas que se ajustan a las formas típicas de los objetos de interés, mejorando la precisión en la detección. La combinación de estas estrategias permite una inferencia más eficiente sin comprometer la calidad de los resultados, lo que hace de YOLOv11 una solución ideal para aplicaciones exigentes en detección de objetos en tiempo real (Wei et al., 2025).

2.4.2.2 Métodos de detección e identificación basado en YOLOv8

La arquitectura YOLOv8, es una variante de los modelos de detección de objetos de la familia YOLO, emplea una red neuronal única para la predicción simultánea de cuadros delimitadores y etiquetas de los objetos presentes en una imagen (Redmon et al., 2016). Existen cinco versiones de YOLOv8: YOLOv8n, YOLOv8s, YOLOv8m, YOLOv8l y YOLOv8x, donde YOLOv8s equilibra mejor la precisión y la velocidad que otras versiones y tiene potencial para la detección en tiempo real (Zhang et al., 2024).

Este algoritmo incluye una estructura dividida en tres componentes principales: la columna vertebral (Backbone), el cuello (Neck) y la cabeza (Head); el backbone de YOLOv8, basado en CSPDarknet, hereda algunos

aspectos de YOLOv5 pero introduce el módulo C2f en lugar del módulo C3, con conexiones parciales entre etapas (Cross Stage Partial o CSP), este módulo C2f combina ideas del módulo ELAN, introducido en YOLOv7, que permite la integración de las características del módulo C3 y ELAN; debido a estas modificaciones YOLOv8 obtiene un flujo de gradiente más detallado y un diseño más ligero, mejorando la capacidad del modelo sin aumentar su complejidad, además al final de la columna vertebral, YOLOv8 utiliza un módulo SPPF (Spatial Pyramid Pooling Fast), que consta de tres capas de agrupación máxima de 5x5, este módulo permite que el modelo identifique objetos en varias escalas sin un aumento considerable en el tamaño del modelo, lo que optimiza la eficiencia de detección. El Neck de YOLOv8 utiliza el módulo PAN-FPN (Path Aggregation Feature Pyramid Network), que permite la fusión bidireccional de características de múltiples escalas, al combinar características de alto nivel con características finas de bajo nivel, el PAN-FPN permite que YOLOv8 capture tanto detalles contextuales como específicos, mejorando la precisión de detección de objetos en diferentes tamaños proporcionando características enriquecidas del campo receptivo pequeño y agrega información contextual de diferentes niveles. Finalmente, el Head de YOLOv8 utiliza una estructura de cabeza desacoplada (Decoupled Head), que separa las tareas de clasificación y de predicción de cuadros delimitadores. en lugar de depender únicamente de la coincidencia de IoU o de una asignación de escala fija, YOLOv8 emplea un asignador alineado con la tarea, que permite una coincidencia más precisa entre muestras positivas y negativas, por tanto, la arquitectura de YOLOv8 está optimizada para realizar predicciones en múltiples escalas (con factores de reducción 8x, 16x y 32x), lo que permite la detección efectiva de objetos pequeños, medianos y grandes. (Li et al., 2024; Niu et al., 2024).

2.4.2.3 Métodos de detección e identificación basado en YOLOv5u

YOLOv5u, desarrollado por Ultralytics, representa una iteración avanzada del modelo YOLOv5, el cual se fundamenta en la familia de modelos YOLO, basados en redes neuronales convolucionales (Ultralytics, 2025a). Este

modelo hereda los principios de diseño de sus predecesores, pero introduce optimizaciones significativas que mejoran la precisión y la eficiencia computacional en tareas de detección de objetos en tiempo real; entre las técnicas innovadoras implementadas en YOLOv5u se encuentran el aumento de datos de mosaico, el entrenamiento autoantagónico y los anclajes adaptativos, los cuales contribuyen a un mejor rendimiento en la detección de objetos en diversos escenarios, estas características permiten al modelo adaptarse a variaciones en las imágenes de entrada, mejorando su robustez frente a condiciones desafiantes, como cambios en la iluminación o la presencia de objetos de diferentes escalas (Naddaf-Sh et al., 2024).

La familia YOLOv5u incluye varias configuraciones diseñadas para adaptarse a diferentes necesidades computacionales y de rendimiento: YOLOv5nu (nano), YOLOv5su (small), YOLOv5mu (medium), YOLOv5lu (large) y YOLOv5xu (extra-large); YOLOv5su, la versión pequeña, mejora la capacidad de detección respecto a la variante nano, manteniendo una eficiencia adecuada para dispositivos de gama media, YOLOv5mu y YOLOv5lu, las versiones mediana y grande, incrementan la profundidad y el número de parámetros de la red, lo que resulta en una mayor precisión a costa de un mayor requerimiento computacional (Gonçalves et al., 2024).

YOLOv5u comparte la estructura principal (backbone) y el cuello (neck) de YOLOv5, basados en la arquitectura CSPDarknet y PANet, pero incorpora un cabezal de detección desacoplado y sin anclajes, inspirado en YOLOv8, esta modificación elimina la dependencia de anclajes predefinidos, permitiendo una detección más flexible y precisa de objetos de diferentes formas y tamaños; la combinación de este cabezal de detección avanzado con técnicas de aumento de datos, como el mosaic augmentation, y métodos de entrenamiento optimizados, posiciona a YOLOv5u como una solución robusta y versátil para aplicaciones de visión por computadora que requieren detección de objetos en tiempo real (Ilyas, 2024).

2.4.3 Métricas de evaluación

Para evaluar el desempeño y rendimiento de los algoritmos de detección de objetos, se utilizaron métricas de detección estándar como la precisión, la recuperación y la precisión media promedio, estas métricas permiten evaluar la exactitud y confiabilidad del modelo en aplicaciones del mundo real, asegurando un equilibrio entre detecciones correctas y errores, teniendo en cuenta el tiempo de inferencia, tiempo que tarda un algoritmo en tomar nuevos datos y hacer predicciones o detecciones, generalmente se expresado en milisegundos (ms), un tiempo de inferencia más bajo es importante para las aplicaciones en tiempo real, ya que conduce a una toma de decisiones rápida, varios factores influyen en el tiempo de inferencia del algoritmo, incluidas las especificaciones de hardware, la arquitectura del algoritmo y las técnicas de optimización (Padilla & Da Silva, 2020).

2.4.3.1 Precisión (precision)

La precisión cuantifica la proporción de detecciones correctas del número total de predicciones realizadas por el algoritmo, se define matemáticamente como:

$$Precision = \frac{True\ positive\ (TP)}{True\ positives\ (TP) + False\ positives\ (FP)}$$

Los verdaderos positivos (TP) es el número de objetos correctamente detectados por el modelo en coincidencia con las anotaciones reales, mientras que los falsos positivos (FP) son los objetos detectados erróneamente que no corresponden con un objeto real. Un valor de precisión más alto indica menos errores de falsos positivos, lo que significa una mejor precisión en las detecciones (Padilla, Netto, & da Silva, 2020).

2.4.3.2 Recuperación (recall)

La recuperación mide la capacidad del modelo para detectar todos los objetos relevantes en el conjunto de datos, se expresa como:

$$Recall = \frac{True\ positive\ (TP)}{True\ Positives\ (TP) + False\ Negatives\ (FN)}$$

Los falsos negativos (FN) es la cantidad de objetos presentes en la imagen que el modelo no detectó. Si la recuperación es alta, indica que el modelo tiene una mayor sensibilidad para identificar objetos de interés, reduciendo los casos en los que no se detectan elementos presentes en la escena, no obstante, un incremento en la recuperación puede conllevar un mayor número de falsos positivos, es decir, detecciones incorrectas de objetos inexistentes. Por ello, es fundamental lograr un equilibrio entre recuperación y precisión, evitando que la mejora en una de estas métricas afecte negativamente el desempeño global del modelo (Grandini et al., 2020).

2.4.3.3 F1- Score

La puntuación F1, una métrica de evaluación del desempeño integral se calcula como la media armónica de precisión y recuperación, su valor varía entre 0 y 1, donde un valor cercano a 1 indica un equilibrio sólido entre no generar falsas alarmas y no omitir objetos reales; y un valor bajo revela desbalance, ya sea por exceso de falsos positivos o por pérdida de verdaderos positivos. (Dong et al., 2025)

$$F1 = 2 \times \left(\frac{P \times R}{P + R} \right)$$

2.4.3.4 Precisión promedio media (mAP, mean Average Precision)

La mAP proporciona una medida global del rendimiento del modelo en la detección de múltiples clases de objetos. Se obtiene calculando la precisión promedio (AP) para cada clase individualmente y luego promediando estos valores:

$$mAP = \left(\frac{1}{N} \right) \times \sum_{i=1}^N (AP_i)$$

Donde N represente el número total de clases de objetos y AP_i representa la precisión promedio para la clase i, calculada como el área bajo la curva (Hirsch & Hofer, 2023).

III. RESULTADOS

3.1 YOLOv5u

3.1.1 Análisis de métricas y costo computacional

En la *Tabla 1*, el recall global pasa de 0.466 a 0.657 y el F1 score de 0.632 a 0.790 indicando mayor capacidad para recuperar instancias y manteniendo un buen equilibrio entre aciertos y errores, por otro lado, el mAP@50 aumenta de 0.726 a 0.824 y el mAP@50:95 de 0.619 a 0.729, la diferencia entre ambos mAP se reduce de 0.107 a 0.095 señal de un encuadre más preciso de las cajas a medida que crece la capacidad del modelo.

En cuanto a las clases, la clase maíz resulta altamente distinguible en toda la familia, la precisión se mantiene entre 0.994 y 0.998, el recall parte de 0.894 en la variante ligera y alcanza 0.973 en la variante mayor, el F1 score se sitúa entre 0.941 y 0.985 y el mAP@50:95 llega a 0.962 en YOLOv5xu, por tanto, el detector identifica y delimita el cultivo con alta fiabilidad y las mejoras que aportan las variantes más grandes son ya marginales para esta clase.

En la clase maleza, la precisión permanece alta y estable entre 0.975 y 0.981, lo que refleja pocas detecciones indebidas, la sensibilidad es la que más progresa: el recall crece de 0.0384 a 0.341; el F1 score avanza de 0.074 a 0.506; el mAP@50 de 0.506 a 0.661; y el mAP@50:95 de 0.370 a 0.496, este patrón es consistente con escenas dominadas por objetos pequeños, oclusiones y alta variabilidad, donde una mayor capacidad del modelo reduce falsos negativos sin comprometer la especificidad.

Por otro lado, el costo computacional aumenta con el tamaño de la variante, el tiempo de entrenamiento se sitúa entre 4.73 y 4.78 horas en YOLOv5nu, YOLOv5su y YOLOv5mu; asciende a 6.025 horas en YOLOv5lu y a 11.003 horas en YOLOv5xu, en inferencia, las variantes más rápidas son YOLOv5mu y YOLOv5su con 170.21 y 170.52 milisegundos por imagen, seguidas de YOLOv5nu con 172.06 milisegundos, la latencia aumenta a 216.88 milisegundos en YOLOv5lu y a 396.12 milisegundos en YOLOv5xu, estas cifras equivalen aproximadamente a 5.9 cuadros por segundo en

los modelos más veloces, 4.6 cuadros por segundo en YOLOv5lu y 2.5 cuadros por segundo en YOLOv5xu, diferencias relevantes para aplicaciones en tiempo real y despliegues con restricciones de hardware.

Por tanto, la elección de la variante debe seguir la prioridad operativa, si el objetivo es maximizar la detección de malezas, YOLOv5xu ofrece el mayor recall y el mayor F1 en la clase limitante, a costa de la mayor latencia de inferencia, pero si se busca un equilibrio entre exactitud y tiempo de respuesta, YOLOv5lu representa un compromiso sólido al mejorar de forma clara la sensibilidad en malezas con un costo temporal intermedio, asimismo, si la rapidez es prioritaria, YOLOv5su y YOLOv5mu permiten procesar cada imagen en alrededor de 170 milisegundos, lo que se traduce en cerca de 5.9 cuadros por segundo, con pérdidas globales moderadas y una sensibilidad más limitada en malezas.

Tabla 1 *Métricas del modelo YOLOv5u*

Modelo	Clase	Precision	Recall	F1 Score	mAP@50	mAP@50:95	Trining time (hours)	Speed (ms)
YOLOv5nu	Maize	0.994	0.894	0.941	0.946	0.862	4.779	172.06
	Weed	0.975	0.0384	0.074	0.506	0.37		
	All	0.984	0.466	0.632	0.726	0.619		
YOLOv5su	Maize	0.997	0.944	0.970	0.971	0.914	4.737	170.52
	Weed	0.976	0.123	0.218	0.549	0.398		
	All	0.986	0.533	0.692	0.76	0.656		
YOLOv5mu	Maize	0.998	0.969	0.983	0.984	0.948	4.728	170.21
	Weed	0.979	0.233	0.376	0.606	0.444		
	All	0.988	0.601	0.747	0.795	0.696		
YOLOv5lu	Maize	0.997	0.971	0.984	0.985	0.956	6.025	216.88
	Weed	0.981	0.302	0.462	0.641	0.475		
	All	0.989	0.636	0.774	0.813	0.715		
YOLOv5xu	Maize	0.997	0.973	0.985	0.986	0.962	11.003	396.12
	Weed	0.981	0.341	0.506	0.661	0.496		
	All	0.989	0.657	0.790	0.824	0.729		


3.1.2 Inspección visual de la predicción del modelo YOLOv5u

El panel de referencia muestra la verdad de terreno con las instancias de maíz y malezas anotadas y los cinco paneles restantes presentan las predicciones de YOLOv5nu, YOLOv5su, YOLOv5mu, YOLOv5lu y YOLOv5xu sobre la misma imagen.

Se observa una progresión clara conforme aumenta la capacidad del modelo, YOLOv5nu evidencia subdetección de malezas pequeñas y encuadres imprecisos; YOLOv5su mejora la cobertura, aunque aún deja vacíos y tiende a sobredimensionar algunas cajas, YOLOv5mu corrige parte de esos desajustes, recupera instancias omitidas y reduce activaciones indebidas sobre bordes y texturas del suelo, por otro lado, YOLOv5lu aproxima con mayor fidelidad la localización a la referencia, con menos omisiones residuales, por último, YOLOv5xu ofrece la cobertura más completa y el encuadre más preciso, con pocos falsos positivos; persisten únicamente omisiones puntuales en zonas muy sombreadas o en malezas de tamaño muy reducido.

En conjunto, las variantes de mayor capacidad incrementan la sensibilidad y refinan la localización sobre la clase malezas sin comprometer la identificación del maíz, mientras que las variantes ligeras concentran sus errores en falsas alarmas inducidas por textura y en la pérdida de instancias pequeñas u ocluidas. *Figura 5*

Figura 5 Inferencia de los modelos YOLOv5u aplicados a maize y weed



3.2 YOLOv8

3.2.1 Análisis de métricas y costo computacional

En la *Tabla 2*, se observa una mejora sostenida del promedio entre maíz y maleza, el recall aumenta de 0.483 a 0.698, el F1 score aumenta de 0.648 a 0.818, el mAP@50 progresa de 0.734 a 0.844 y el mAP@50:95 asciende de 0.632 a 0.752, la diferencia entre mAP@50 y mAP@50:95 se reduce de 0.102 a 0.092, lo que indica un ajuste de cajas más preciso a medida que crece la capacidad del modelo.

En cuanto a las clases, la clase maíz presenta un rendimiento alto desde las variantes ligeras y presenta un desempeño cercano al óptimo a partir de YOLOv8m, la precisión se mantiene entre 0.995 y 0.998, el recall avanza de 0.920 a 0.975, el F1 score se sitúa entre 0.956 y 0.986 y el mAP@50:95 llega a 0.968 en YOLOv8x, estos resultados muestran identificación y localización fiables del cultivo en todas las variantes.

Po otro lado, las malezas concentran la mayor dificultad, la precisión permanece elevada y estable entre 0.970 y 0.981, la sensibilidad mejora con el tamaño del modelo: el recall pasa de 0.047 en YOLOv8n a 0.420 en YOLOv8x, en paralelo, el F1 score aumenta de 0.090 a 0.588, el mAP@50 sube de 0.508 a 0.701 y el mAP@50:95 avanza de 0.378 a 0.537, esta tendencia describe una ganancia progresiva en la recuperación y en la calidad de localización para instancias difíciles.

Asimismo, el costo computacional crece junto con la capacidad, el tiempo de entrenamiento aumenta de 4.320 horas en YOLOv8n a 10.363 horas en YOLOv8x, la latencia de inferencia reportada en milisegundos por imagen pasa de 155.52 en YOLOv8n a 373.08 en YOLOv8x, con valores intermedios de 157.19 en YOLOv8s, 217.51 en YOLOv8m y 278.52 en YOLOv8l, estos resultados describen con claridad el compromiso entre exactitud y tiempo de respuesta dentro de la familia YOLOv8.

Por tanto, cuando el objetivo es maximizar la detección de malezas, YOLOv8x ofrece los valores más altos de recall y F1 score en la clase limitante, asumiendo el mayor tiempo de inferencia; si se busca un equilibrio entre exactitud y eficiencia temporal, YOLOv8l constituye un compromiso robusto al mejorar de forma clara la sensibilidad en malezas con un costo intermedio; cuando la velocidad de procesamiento es prioritaria, YOLOv8n

y YOLOv8s proporcionan los menores tiempos de inferencia, a cambio de una sensibilidad más acotada en malezas.

Tabla 2 *Métricas del modelo YOLOv8*

Modelo	Clase	Precision	Recall	F1	mAP@50	mAP@50:95	Trining time (horas)	Speed (ms)
				Score				
YOLOv8n	Maize	0.996	0.92	0.956	0.96	0.886	4.320	155.52
	Weed	0.97	0.047	0.090	0.508	0.378		
	All	0.983	0.483	0.648	0.734	0.632		
YOLOv8s	Maize	0.995	0.96	0.977	0.98	0.932	4.366	157.19
	Weed	0.979	0.146	0.254	0.562	0.413		
	All	0.987	0.553	0.709	0.771	0.672		
YOLOv8m	Maize	0.998	0.971	0.984	0.985	0.958	6.042	217.51
	Weed	0.981	0.29	0.448	0.635	0.473		
	All	0.989	0.63	0.770	0.81	0.715		
YOLOv8l	Maize	0.996	0.975	0.985	0.987	0.965	7.737	278.52
	Weed	0.981	0.368	0.535	0.675	0.507		
	All	0.988	0.672	0.800	0.831	0.736		
YOLOv8x	Maize	0.997	0.975	0.986	0.987	0.968	10.363	373.08
	Weed	0.981	0.42	0.588	0.701	0.537		
	All	0.989	0.698	0.818	0.844	0.752		

3.2.3 Inspección visual de la predicción del modelo YOLOv8


El panel de referencia muestra la verdad de terreno y, a su lado, las salidas de YOLOv8n, YOLOv8s, YOLOv8m, YOLOv8l y YOLOv8x aplicadas a la misma imagen; la detección de maíz se mantiene estable en toda la familia, las diferencias aparecen sobre todo en la recuperación de malezas pequeñas, en la capacidad para separar individuos próximos y en la tolerancia a la textura granular del suelo.

YOLOv8n deja sin marcar varias malezas de tamaño reducido y delimita algunos objetos con cajas poco ceñidas, además de activar puntualmente sobre grumos del terreno, YOLOv8s aumenta la cobertura, pero aún muestra cajas algo amplias y disparos residuales sobre patrones del fondo, con YOLOv8m se observa un contorno más preciso y una disminución clara de falsos positivos, manteniendo mejor la separación entre plantas

adyacentes, YOLOv8l mejora la correspondencia con la referencia y sostiene detecciones en zonas de menor contraste local, con geometrías de caja más estables, finalmente, YOLOv8x alcanza la mayor recuperación y el posicionamiento más consistente de las cajas, con mínima confusión ante texturas y bordes; los fallos que persisten se concentran en malezas muy pequeñas o parcialmente sombreadas.

En conjunto, el incremento de capacidad dentro de YOLOv8 se traduce en mayor sensibilidad y mejor ajuste espacial sobre la clase malezas sin comprometer la identificación del maíz. *Figura 6*

Figura 6 Inferencia de los modelos YOLOv8 aplicados a maize y weed



3.3 YOLOv11

3.3.1 Análisis de métricas y latencia de inferencia

En la *Tabla 3*, se aprecia una mejora sostenida desde YOLO11n hasta YOLO11x, conforme aumenta la capacidad del modelo, el recall global pasa de 0.479 a 0.609; el F1 score global se incrementa de 0.645 a 0.754; el mAP@50 asciende de 0.733 a 0.799; y el mAP@50:95 progresa de 0.620 a 0.705, estos avances se traducen en mayor cobertura de verdaderos positivos, mejor equilibrio entre precisión y sensibilidad y un ajuste espacial más exigente de las cajas.

La clase maíz mantiene un rendimiento alto y estable en toda la familia, la precisión permanece en el intervalo 0.995 - 0.996, el recall avanza de 0.913 a 0.975 y el F1 score se sitúa entre 0.952 y 0.985; en localización, el mAP@50 alcanza 0.986 en las variantes de mayor tamaño y el mAP@50:95 llega hasta 0.953, estos resultados indican que el detector identifica y delimita el cultivo con elevada fiabilidad, con ganancias ya marginales al escalar el modelo.

En cuanto a las malezas, la precisión se mantiene alta y estable, entre 0.976 y 0.980, lo que evidencia una baja tasa de detecciones indebidas, la sensibilidad mejora con el tamaño de la variante: el recall pasa de 0.0455 en YOLO11n a 0.246 en YOLO11x; en consonancia, el F1 score aumenta de 0.087 a 0.393, por otro lado, la calidad de localización acompaña estas tendencias, con mAP@50 que sube de 0.510 a 0.613 y mAP@50:95 que avanza de 0.373 a 0.461.

En el costo computacional, el tiempo de entrenamiento aumenta de 5.283 horas en YOLO11n a 7.928 horas en YOLO11x, con un máximo de 9.419 horas en YOLO11l, el tiempo de inferencia también se incrementa, desde 190.20 milisegundos por imagen en YOLO11n hasta 401.96 milisegundos por imagen en YOLO11x, con valores intermedios de 195.22, 251.09 y 339.10 milisegundos por imagen.

Desde la perspectiva aplicada, la selección debe alinearse con la prioridad operativa, cuando el objetivo es maximizar la detección de malezas, YOLO11x ofrece los valores más altos de recall y F1 score en la clase limitante, a cambio del mayor tiempo de inferencia, si se requiere equilibrio entre exactitud y eficiencia temporal, YOLO11l representa un compromiso sólido al mejorar la sensibilidad en malezas con un costo intermedio y cuando la velocidad de procesamiento es prioritaria, YOLO11n y YOLO11s proporcionan los menores tiempos de inferencia.

Tabla 3 Métricas de YOLOv11

Modelo	Clase	Precision	Recall	F1 Score	mAP@50	mAP@50:95	Trining time (horas)	Speed (ms)
YOLO11n	Maize	0.995	0.913	0.952	0.955	0.867	5.283	190.20
	Weed	0.976	0.0455	0.087	0.51	0.373		
	All	0.985	0.479	0.645	0.733	0.62		
YOLO11s	Maize	0.996	0.951	0.973	0.975	0.924	5.423	195.22
	Weed	0.98	0.134	0.236	0.557	0.409		
	All	0.988	0.542	0.700	0.766	0.666		
YOLO11m	Maize	0.996	0.975	0.985	0.986	0.953	6.975	251.09
	Weed	0.978	0.228	0.370	0.603	0.451		
	All	0.987	0.601	0.747	0.795	0.702		
YOLO11l	Maize	0.995	0.973	0.984	0.986	0.951	9.419	339.10
	Weed	0.981	0.237	0.382	0.609	0.455		
	All	0.988	0.605	0.750	0.797	0.703		
YOLO11x	Maize	0.996	0.973	0.984	0.985	0.95	7.928	401.96
	Weed	0.98	0.246	0.393	0.613	0.461		
	All	0.988	0.609	0.754	0.799	0.705		


3.3.2 Inspección visual de la predicción del modelo YOLOV11

En la *Figura 7*, el panel de referencia presenta la verdad de terreno y, a su derecha, se muestran las salidas de YOLOv11n, YOLOv11s, YOLOv11m, YOLOv11l y YOLOv11x aplicadas sobre la misma imagen, la familia mantiene estable la identificación de maíz y difiere principalmente en la recuperación y el encuadre de malezas.

YOLOv11n ofrece una sensibilidad limitada, varias malezas pequeñas no se activan y algunas cajas quedan descentradas o poco ceñidas; YOLOv11s eleva la respuesta pero aún deja huecos y en ocasiones extiende las cajas más allá del contorno real, con activaciones aisladas sobre texturas del suelo; YOLOv11m alcanza un punto de equilibrio: mejora la delimitación geométrica, reduce disparos espurios y separa con mayor limpieza malezas contiguas; a partir de ahí, YOLOv11l incrementa la densidad de hallazgos válidos sin penalizar la selectividad, los perímetros de las cajas resultan más coherentes con la referencia y las omisiones residuales se vuelven poco frecuentes.

En el extremo superior de capacidad, YOLOv11x muestra la cobertura más amplia y la estabilidad posicional más alta: mantiene puntuaciones de confianza elevadas, minimiza respuestas a bordes o brillos del terreno y conserva el encuadre aún bajo variaciones locales de iluminación; en síntesis, el salto hacia YOLOv11l y YOLOv11x aporta ganancias concretas en sensibilidad y precisión espacial sobre la clase malezas sin comprometer la correcta identificación del cultivo, los errores restantes se concentran en individuos muy pequeños, parcialmente ocluidos o en zonas de bajo contraste.

Figura 7 Inferencia de los modelos YOLOv11 aplicados a maize y weed




3.4 Comparación y selección de deep learning

La *Figura 8* sintetiza la precisión, recall y F1 para las familias de YOLO a lo largo de sus variantes n, s, m, l y x; en las tres arquitecturas la precisión se mantiene altas, con valores en torno a 0.99 en todas las variantes, mostrando una baja tasa de falsas alarmas prácticamente independiente del tamaño del modelo.

El recall muestra una mejora monótona al aumentar la capacidad en cada familia, en promedio entre clases YOLOv5 progresa desde 0.466 en la variante pequeña hasta 0.657 en la variante grande; YOLOv8 avanza desde 0.483 hasta 0.698; y YOLO11 pasa de 0.479 a 0.609, y, en consecuencia, el F1 también crece con el tamaño: YOLOv5 sube de 0.632 a 0.790, YOLOv8 de 0.648 a 0.818 y YOLO11 de 0.645 a 0.754.

Comparativamente, YOLOv8 alcanza los valores más altos de recall y F1 en todo el rango de variantes, seguido por YOLOv5, mientras que YOLO11 queda por detrás en estas métricas, además se observan rendimientos decrecientes al pasar de “l” a “x”, especialmente en YOLO11 donde las ganancias en recall son pequeñas, en YOLOv8 y YOLOv5 las mejoras finales son moderadas.

Figura 8 Precisión, recall y F1 Score por familia Yolo



Por otro lado, el $mAP@50:95$ crece con el número de parámetros en las tres familias, aunque con rendimientos decrecientes, las ganancias más notorias aparecen al pasar de variantes ligeras a medianas; a partir de ese punto las mejoras son más pequeñas, para tamaños comparables, YOLOv8 se sitúa de manera consistente por encima de YOLOv5 y de YOLO11, que muestra una saturación temprana. *Figura 9a*


En cuanto al tiempo de entrenamiento, este aumenta con la complejidad del modelo, YOLOv8 sigue una tendencia ascendente casi monótona desde la variante pequeña hasta la extragrande, YOLOv5 es competitivo en los tamaños pequeños y medianos, pero su variante mayor requiere el mayor tiempo de entrenamiento del conjunto y en YOLO11 el máximo de tiempo se observa en la variante grande y desciende en la extragrande, lo que sugiere diferencias de eficiencia según el tamaño. *Figura 9b*

Al relacionar $mAP@50:95$ con la latencia de inferencia se hace visible el compromiso entre precisión y tiempo de respuesta; para latencias similares, YOLOv8 ofrece el mayor mAP y domina en la mayor parte, YOLOv5 ocupa una posición intermedia y YOLO11 queda por detrás en exactitud para el mismo presupuesto temporal, se aprecia un punto de inflexión en

latencias bajas y medias, donde pequeñas subidas de latencia aún rinden mejoras sustanciales de mAP; más allá de ese punto, los beneficios adicionales son modestos. *Figura 9c*

Por consiguiente, se sugiere que YOLOv8 es la familia más ventajosa en este conjunto de datos, si el fin es maximizar la exactitud sin restricciones de tiempo de respuesta, la variante extragrande de YOLOv8 alcanza el mayor mAP@50:95, si se busca un equilibrio entre precisión y latencia, la variante grande de YOLOv8 ofrece el mejor compromiso, al combinar un mAP elevado con un tiempo de inferencia moderado.

Figura 9 Rendimiento y latencia en familias YOLO



3.5 Determinación del modelo final y caracterización de YOLOv8x

En base en la comparación entre familias y tamaños, se adopta YOLOv8x como modelo final, puesto que combina la mayor recuperación de malezas con una localización precisa y un comportamiento estable entre escenas, aun cuando exige el mayor tiempo de inferencia.

Las curvas de la *Figura 10*, muestran un aprendizaje bien comportado donde las pérdidas de caja, clasificación y distribución descienden de manera sostenida en entrenamiento y validación, mientras que la precisión, el recall y los mAP aumentan de forma continua hacia el final del proceso, esta cercanía entre las trayectorias de entrenamiento y validación muestra buena generalización y ausencia de sobreajuste relevante.

Por otro lado, la *Figura 11* detalla los patrones de acierto y confusión, Maize y background alcanzan tasas de acierto cercanas a la unidad, mientras que Weed concentra la dificultad; alrededor de tres cuartas partes de las instancias se clasifican correctamente y el resto se

confunden con el fondo; pero este comportamiento es coherente con la presencia de objetos pequeños, oclusiones y alta variabilidad intraclase.

El F1 macro alcanza su máximo alrededor de una confianza de 0.24, que ofrece un equilibrio adecuado entre precisión y sensibilidad; las curvas precisión - recall confirman un área muy alta para Maize y menor para Weed, en aplicaciones donde se priorice detectar la mayor cantidad posible de malezas, conviene fijar una confianza algo inferior a ese valor para ganar recall con una penalización moderada en precisión, y si, la prioridad es contener las falsas alarmas, es preferible aumentar la confianza por encima del óptimo global para reforzar la especificidad. *Figura 12*

Por ende, se respalda la elección de YOLOv8x como modelo final ya que entrena de forma estable, generaliza bien, mantiene desempeño sobresaliente en maíz y alcanza la mayor sensibilidad en malezas dentro de las variantes evaluadas, con un umbral de decisión claramente caracterizado para adaptar la operación al objetivo del despliegue.

Figura 10 *Curvas de entrenamiento y validación de YOLOv8x*




Figura 11 *Matriz de confusión normalizada*





Figura 12 Evaluación por umbral: F1 y Precisión - Recall de YOLOv8x




3.5.1 Verificación en campo

El modelo YOLOv8x fue evaluado mediante un conjunto de seis imágenes originales no incluidas en el entrenamiento, procesadas a una resolución de 640 píxeles, con un umbral de confianza establecido en 0.50 y un umbral de intersección sobre unión (IoU) de 0.50. *Figura 13.* En la imagen (a), el modelo identificó simultáneamente una planta de maíz con una confianza de 0.64 y un conjunto de malezas adyacentes con una confianza de 0.76, distribuidas sobre suelo desnudo y en proximidad a una manguera de riego; los cuadros delimitadores muestran una correspondencia precisa con los contornos visibles, con valores de confianza elevados.

En la imagen (b), se detectó un individuo de maíz con una confianza de 0.95 y malezas con 0.63, evidenciando una adecuada discriminación espacial. En la imagen (c), se registró una detección de maíz con 0.91 de confianza y malezas con 0.91, con contornos bien definidos. En la imagen (d), el modelo identificó un maíz con 0.84 de confianza y múltiples malezas con confianza variando entre 0.66 y 0.98. En la imagen (e), se detectó un maíz con 0.92 de confianza y malezas con valores entre 0.56 y 0.83, con delimitaciones consistentes. Finalmente, en la imagen (f), se obtuvo una detección de maíz con 0.92 de confianza y malezas con rangos de 0.54 a 0.66, manteniendo precisión en los contornos.

La evaluación cualitativa del modelo YOLOv8x demuestra una generalización robusta a condiciones de campo reales, preservando la identificación precisa de maíz, exhibiendo especificidad frente a texturas de suelo y elementos de riego, y optimizando la detección de malezas en función de su tamaño y separación espacial.

Figura 13 Evaluación visual del modelo YoloV8x



IV. DISCUSIÓN

La comparación controlada entre YOLOv5u, YOLOv8 y YOLOv11, usando la misma forma de entrenamiento para todos, mostró a YOLOv8 como la opción más consistente para detectar malezas en maíz de manera autónoma y eficiente, en nuestro conjunto de prueba, YOLOv8x alcanzó $mAP@50:95 = 0.752$, superando a $YOLOv5xu = 0.729$ y $YOLOv11x = 0.705$, y mantuvo $mAP@50 = 0.844$ con recall de malezas = 0.698, estas ventajas se notaron sobre todo en malezas pequeñas o parcialmente tapadas, donde los mecanismos del modelo para combinar información a diferentes tamaños ayudan a recuperar más casos sin aumentar demasiado los errores. Trabajos en contextos agrícolas difíciles muestran que modelos más ligeros y bien ajustados pueden lograr alta precisión con menos recursos, por ejemplo, una versión compacta de YOLOv5 para espigas de trigo logró $mAP@50$ competitivo con alrededor de 1.2 M de parámetros y 3.7 GFLOP, útil para dispositivos portátiles (Huynh et al., 2025).

Al revisar las métricas, apareció una diferencia clara por clase: el maíz mantuvo $F1 = 0.818$ de forma estable entre familias, mientras que malezas fue más difícil por su tamaño reducido, por estar tapadas en parte y por su bajo contraste con el suelo; la literatura coincide en que, cuando hay muchos objetos pequeños y cercanos, los modelos base pueden perder instancias o juntarlas en una sola, mejoras como módulos de atención y combinación más cuidadosa de detalles finos aumentan tanto $mAP@50$ como $mAP@50-95$ (Hou et al., 2025a); en enfermedades foliares de maíz, agregar convoluciones multiescala y atención selectiva ayuda a rescatar detalles y mantener altas velocidades, lo que apunta a una vía concreta para subir nuestro recall de malezas desde 0.698 sin bajar $F1$ (Meng et al., 2025).

La prueba con imágenes propias de campo mostró que el modelo se adapta al entorno real, con tamaño de entrada 640 y los mismos límites fijados en validación, YOLOv8x mantuvo detecciones coherentes bajo texturas de suelo cambiantes, sombras y oclusiones leves; por otro lado, en pepino, un modelo ligero basado en YOLOv11n que añade capas especiales para objetos pequeños, atención deformable y poda de canales, logró $mAP@50 = 93.8\%$ y 218 cuadros por segundo, probando que reforzar los niveles de detalle y compactar el modelo mejora precisión y velocidad en escenas complejas (Liu et al., 2025); asimismo, en banano, una comparación de modelos YOLO v1-v12 ubicó a YOLOv12n como la opción más

equilibrada ($mAP@50 = 93\%$, $mAP@50-95 = 51\%$, 5.1 ms de tiempo de respuesta), lo que respalda la importancia de equilibrar calidad y rapidez para uso en móviles (Baglat et al., 2025).

En cultivos de fresa y aguacate, una comparación entre modelos reportó el mejor equilibrio de precisión y cuadros por segundo con YOLOv6, útil para clasificar estados de madurez en condiciones naturales (Kamat et al., 2025). En sembríos de algodón, combinar imágenes sintéticas generadas por IA con mejoras basadas en YOLOv11 elevó la detección de enfermedades de hoja a $mAP@50 = 96.7\%$, con precisión = 94.8% y recuperación = 93.1%, mostrando que aumentar las clases poco representadas y usar atención ayuda a generalizar mejor (Gao et al., 2025). En maíz, YOLOv8 ha logrado altos niveles de precisión para enfermedades y plagas en campo, en línea con nuestra observación de estabilidad entre escenas (Wu et al., 2024), y en detección de malezas con flujos sencillos de entrenamiento, se han reportado precisiones cercanas a 74%, lo que refuerza la viabilidad práctica de la familia YOLOv8 (Singh et al., 2025).

Asimismo, en invernaderos de fresa con oclusión y objetos pequeños, el modelo YOLO11 ultraligero con submuestreo adaptativo, refuerzo de bordes y atención espacial y de canal logró $mAP@50 = 86.5\%$ con un modelo de 4.6 MB, mejorando precisión y recuperación respecto al base, y manteniendo un tamaño apto para dispositivos en el borde (Li et al., 2025). En fresas y guisantes con el uso de drones, un sistema profundo alcanzó 95.3% de precisión para malezas y 94.73% de precisión global, mostrando que es posible integrar la detección con pulverizadores de precisión en campo (Khan et al., 2025); en conjunto, estas pruebas sugieren que YOLOv8x es preferible cuando se prioriza calidad y hay GPU disponibles; si el límite es el tiempo de respuesta o la memoria, conviene elegir variantes más ligeras o compactar el modelo.

Una de las limitaciones fueron la gran variedad de formas de las malezas y su tamaño pequeño elevan el riesgo de pasarlas por alto, para reducirlo, usamos aumentación de imágenes (cambios fotométricos y geométricos), revisamos las anotaciones y elegimos el modelo, la resolución de 640 fue eficiente, pero puede ser justa para objetos diminutos; los resultados en banano y pepino sugieren explorar resoluciones más altas, dividir la imagen en

mosaicos, añadir capas específicas para detalle fino, atención, o convoluciones multiescala para reforzar la señal de objetos pequeños (Hou et al., 2025b).

En resumen, esta investigación mostró que un enfoque comparativo con protocolo de entrenamiento homogéneo y evaluación multifactorial, permite discriminar con claridad que arquitectura resulta más pertinente para la detección de malezas en maíz; al contrastar familias y tamaños, y al validarlo sobre un conjunto público y un conjunto de imágenes propias de campo, constatamos que el aumento de capacidad mejora de forma sostenida la recuperación de malezas y la calidad de localización, aunque con retornos decrecientes y mayor costo temporal. La selección de YOLOv8x como modelo final responde a ese balance entre sensibilidad y especificidad que exige el manejo selectivo, y a su estabilidad entre escenas con variabilidad real.

V. CONCLUSIONES

- YOLOv8x presentó el mayor desempeño global, con recall de malezas = 0.698, F1 = 0.818, mAP@50 = 0.844 y mAP@50–95 = 0.752, superando a YOLOv5xu y YOLOv11x, estos resultados sustentan su elección cuando la prioridad es maximizar la detección de malezas, aun con mayor latencia de inferencia.
- La clase maíz mantuvo alta precisión y F1 en todas las familias, mientras que malezas constituyó el principal reto por el predominio de instancias pequeñas, ocluidas y de bajo contraste, en YOLOv8, el recall de malezas aumentó de 0.047 (variante ligera) a 0.420 (variante grande) y el F1 de 0.090 a 0.588, evidenciando que el escalado del modelo reduce falsos negativos sin comprometer la especificidad.
- El incremento del tamaño del modelo mejoró la exactitud, pero elevó el costo de cómputo; en YOLOv8, la latencia creció de 155.52 ms a 373.08 ms por imagen y el tiempo de entrenamiento de 4.320 h a 10.363 h, por tanto, la selección del modelo debe equilibrar calidad de detección y tiempo de respuesta según el hardware disponible.
- En el conjunto independiente de campo, YOLOv8x mantuvo detecciones coherentes de maíz y malezas, para la operación en terreno se recomienda ajustar umbrales por clase, calibrar la supresión no máxima en escenas densas y reforzar aumentaciones orientadas a objetos pequeños y bajo contraste para incrementar la sensibilidad sin pérdida de precisión.
- Se concluye que los modelos de la familia YOLO son viables para detectar malezas en condiciones reales de campo y pueden sustentar aplicación en sitio-específico de herbicidas, es decir, tratar únicamente las áreas donde se detecta maleza, además del monitoreo planta a planta en agricultura de precisión.

VI. RECOMENDACIONES

- Usar YOLOv8x como modelo base y reentrenarlo con pocas imágenes por zona y campaña; determinar la cantidad mínima de datos y verificar la estabilidad entre campos y fechas.
- Evaluar el modelo YOLOv8x en diferentes distanciamientos y densidades de maíz; repetir en otras localidades con climas y suelos distintos para comprobar la generalización del sistema.
- Capturar imágenes de 1 a 2 m de altura para obtener una distancia de muestreo en tierra más fina (mayor resolución espacial) y mejorar la detección de malezas pequeñas u ocultas; registrar hora y condiciones de luz para reducir la variabilidad.
- Ampliar y depurar el conjunto de datos con más ejemplos de malezas pequeñas/ocultas; equilibrar las clases, reforzar el control de calidad de etiquetas y versionar el dataset y sus metadatos.
- Desarrollar una app móvil o web de fácil acceso para capturar y cargar imágenes para obtener detecciones en campo.

VII. REFERENCIAS BIBLIOGRÁFICAS

- Programa de Desarrollo Productivo Agrario Rural (AgroRural). (2019). Cultivo de Maíz Amiláceo (Zea mays L.). *Ministerio de Agricultura y Riego*. <http://repositorio.midagri.gob.pe:80/jspui/handle/20.500.13036/304>
- Ahadian, K., Yudistira, N., & Rahayudi, B. (2023). *Corn Disease Classification Using Convolutional Neural Network with Weighted Loss*. <https://doi.org/10.2139/SSRN.4678951>
- Ahmad, J., Muhammad, K., Ahmad, I., Ahmad, W., Smith, M. L., Smith, L. N., Jain, D. K., Wang, H., & Mehmood, I. (2018). Visual features based boosted classification of weeds for real-time selective herbicide sprayer systems. *Computers in Industry*, 98, 23–33. <https://doi.org/10.1016/J.COMPIND.2018.02.005>
- Baglat, P., Hayat, A., Mostafa, S. S., Mendonça, F., & Morgado-Dias, F. (2025). Comparative analysis and evaluation of YOLO generations for banana bunch detection. *Smart Agricultural Technology*, 12. <https://doi.org/10.1016/J.ATECH.2025.101100>
- Bajwa, A. A., Mahajan, G., & Chauhan, B. S. (2015). Nonconventional Weed Management Strategies for Modern Agriculture. *Weed Science*, 63(4), 723–747. <https://doi.org/10.1614/WS-D-15-00064.1>
- Behmann, J., Mahlein, A. K., Rumpf, T., Römer, C., & Plümer, L. (2015). A review of advanced machine learning methods for the detection of biotic stress in precision crop protection. *Precision Agriculture*, 16(3), 239–260. <https://doi.org/10.1007/S11119-014-9372-7/METRICS>
- Costamagna, M., Panero, J., Peretti, G., Felissia, S. F., Lurgo, G., & Cicioli, M. (2017). Detección en tiempo real de malezas a través de técnicas de visión artificial. *XIX Workshop de Investigadores En Ciencias de La Computación*, 301–304. <http://sedici.unlp.edu.ar/handle/10915/62514>
- Detection. (2022). *Weed Dataset*. Roboflow. <https://universe.roboflow.com/detection-rni73/weed-xnmcb>

- Dong, S., Wang, Y., Cao, J., Ma, J., Chen, Y., & Kang, X. (2025). Advanced lightweight deep learning vision framework for efficient pavement damage identification. *Scientific Reports*, 15(1), 1–15. <https://doi.org/10.1038/S41598-025-97132-X>;SUBJMETA=1075,166,624,639,986;KWRD=APPLIED+OPTICS,CIVIL+ENGINEERING
- Elsayed, A., Nasr, O., Elzokm, A., Aly, Y., Youssef, S. M., & Fathalla, K. M. (2024). Robotics Technology and Computer Vision for Precision Agriculture. *2024 International Conference on Machine Intelligence and Smart Innovation, ICMISI 2024 - Proceedings*, 179–185. <https://doi.org/10.1109/ICMISI61517.2024.10580452>
- Gao, L., Ran, T., Zou, H., & Wu, H. (2025). Cotton Leaf Disease Detection Using LLM-Synthetic Data and DEMM-YOLO Model. *Agriculture (Switzerland)*, 15(15). <https://doi.org/10.3390/AGRICULTURE15151712>
- García Mendoza, P. J. (2017). El cultivo del maíz en el mundo y en Perú. *Revista de Investigaciones de La Universidad Le Cordon Bleu*, 4(2), 73–79. <https://doi.org/10.36955/RIULCB.2017v4n2.005>
- Gonçalves, L. A. O., Ghali, R., & Akhloufi, M. A. (2024). YOLO-Based Models for Smoke and Wildfire Detection in Ground and Aerial Images. *Fire 2024, Vol. 7, Page 140*, 7(4), 140. <https://doi.org/10.3390/FIRE7040140>
- Grandini, M., Bagli, E., & Visani, G. (2020). *Metrics for Multi-Class Classification: an Overview*. <https://doi.org/https://doi.org/10.48550/arXiv.2008.05756>
- Hasan, A. S. M. M., Soheli, F., Diepeveen, D., Laga, H., & Jones, M. G. K. (2021a). A survey of deep learning techniques for weed detection from images. *Computers and Electronics in Agriculture*, 184, 106067. <https://doi.org/10.1016/J.COMPAG.2021.106067>
- Hasan, A. S. M. M., Soheli, F., Diepeveen, D., Laga, H., & Jones, M. G. K. (2021b). A survey of deep learning techniques for weed detection from images. *Computers and Electronics in Agriculture*, 184, 106067. <https://doi.org/10.1016/J.COMPAG.2021.106067>

- Hirsch, T., & Hofer, B. (2023). The MAP Metric in Information Retrieval Fault Localization. *2023 38th IEEE/ACM International Conference on Automated Software Engineering (ASE)*, 1480–1491. <https://doi.org/10.1109/ASE56229.2023.00041>
- Hou, S., Pang, Y., Wang, J., Hou, J., & Wang, B. (2025a). RS-YOLO: A highly accurate real-time detection model for small-target pest. *Smart Agricultural Technology*, 12. <https://doi.org/10.1016/J.ATECH.2025.101212>
- Hou, S., Pang, Y., Wang, J., Hou, J., & Wang, B. (2025b). RS-YOLO: A highly accurate real-time detection model for small-target pest. *Smart Agricultural Technology*, 12. <https://doi.org/10.1016/J.ATECH.2025.101212>
- Hu, K., Coleman, G., Zeng, S., Wang, Z., & Walsh, M. (2020). Graph weeds net: A graph-based deep learning method for weed recognition. *Computers and Electronics in Agriculture*, 174, 105520. <https://doi.org/10.1016/J.COMPAG.2020.105520>
- Hussain, M. (2023). YOLO-v1 to YOLO-v8, the Rise of YOLO and Its Complementary Nature toward Digital Manufacturing and Industrial Defect Detection. *Machines*, 11(7), 677. <https://doi.org/10.3390/machines11070677>
- Huynh, P.-T., Pham, N.-Q., Nguyen, V.-P., & Huynh-The, T. (2025). Efficient Wheat Head Detection via Lightweight Deep Learning with YOLOv5 Enhancements. In *Communications in Computer and Information Science: Vol. 2585 CCIS* (pp. 70–83). Springer Science and Business Media Deutschland GmbH. https://doi.org/10.1007/978-3-031-98164-7_6
- Instituto Interamericano de Cooperación para la Agricultura (IICA). (2013). La cadena de valor del maíz en el Perú. *Instituto Interamericano de Cooperación Para La Agricultura*. <https://iica.int/es>
- Ilyas, M. (2024). *Comparative Analysis and Optimization of YOLOv5u, YOLOv9, and YOLOv10 Deep Learning Models for Real-Time Wildfire Detection*. <https://erepo.uef.fi/handle/123456789/33454>

- Kamat, P., Gite, S., Chandekar, H., Dlima, L., & Pradhan, B. (2025). Multi-class fruit ripeness detection using YOLO and SSD object detection models. *Discover Applied Sciences*, 7(9). <https://doi.org/10.1007/S42452-025-07617-7>
- Khan, S., Tufail, M., Khan, M. T., Khan, Z. A., & Anwar, S. (2021). Deep learning-based identification system of weeds and crops in strawberry and pea fields for a precision agriculture sprayer. *Precision Agriculture*, 22(6), 1711–1727. <https://doi.org/10.1007/S11119-021-09808-9/METRICS>
- Khan, Z., Liu, H., Shen, Y., Yang, Z., Zhang, L., & Yang, F. (2025). Optimizing precision agriculture: A real-time detection approach for grape vineyard unhealthy leaves using deep learning improved YOLOv7 with feature extraction capabilities. *Computers and Electronics in Agriculture*, 231, 109969. <https://doi.org/10.1016/J.COMPAG.2025.109969>
- Kumar, V., Kumari, A., Price, A. J., Bana, R. S., Singh, V., & Bamboriya, S. D. (2023). Impact of Futuristic Climate Variables on Weed Biology and Herbicidal Efficacy: A Review. *Agronomy* 2023, Vol. 13, Page 559, 13(2), 559. <https://doi.org/10.3390/AGRONOMY13020559>
- Li, Z., Hu, X., Zhao, X., Ye, H., Chen, F., Chen, X., & Li, X. (2025). Beyond obstacles: feather-light YOLO11-LES for real-time ripeness detection of occluded strawberries in greenhouses. *Journal of Real-Time Image Processing*, 22(5). <https://doi.org/10.1007/S11554-025-01748-1>
- Li, Z., Wang, D., Yan, Q., Zhao, M., Wu, X., & Liu, X. (2024). Winter wheat weed detection based on deep learning models. *Computers and Electronics in Agriculture*, 227, 109448. <https://doi.org/10.1016/J.COMPAG.2024.109448>
- Liu, B., & Bruch, R. (2020). Weed Detection for Selective Spraying: a Review. *Current Robotics Reports* 2020 1:1, 1(1), 19–26. <https://doi.org/10.1007/S43154-020-00001-W>
- Liu, J., Wang, X., Chen, Q., Yan, P., & Liu, X. (2025). Deep learning method for cucumber disease detection in complex environments for new agricultural productivity. *BMC Plant Biology*, 25(1). <https://doi.org/10.1186/S12870-025-06841-Y>

- Liu, L., Ouyang, W., Wang, X., Fieguth, P., Chen, J., Liu, X., & Pietikäinen, M. (2020). Deep Learning for Generic Object Detection: A Survey. *International Journal of Computer Vision*, 128(2), 261–318. <https://doi.org/10.1007/S11263-019-01247-4/FIGURES/21>
- López, A. F. J., Pico, D. A. C., & Ramírez, D. Y. G. (2020). Intelligent system for weeds management in pineapple crop with precision agriculture concepts. *Ciencia y Agricultura*, 17(3), 122–136. <https://doi.org/10.19053/01228420.V17.N3.2020.10830>
- Mehraj, S., Manzoor, M. R. M. M., Sharma, R. K., Mir, A. H., Khan, I. L., & Maqbool, S. (2022). Climate Change and Agriculture. *Environmental Studies and Climate Change*, 231–239. <https://doi.org/10.1201/9781003220824-17>
- Meng, Y., Zhan, J., Li, K., Yan, F., & Zhang, L. (2025). A rapid and precise algorithm for maize leaf disease detection based on YOLO MSM. *Scientific Reports*, 15(1). <https://doi.org/10.1038/S41598-025-88399-1>
- Mohanty, S. P., Hughes, D. P., & Salathé, M. (2016). Using deep learning for image-based plant disease detection. *Frontiers in Plant Science*, 7(September), 215232. <https://doi.org/10.3389/FPLS.2016.01419/BIBTEX>
- Moldvai, L., Mesterházi, P. Á., Teschner, G., & Nyéki, A. (2024). Weed Detection and Classification with Computer Vision Using a Limited Image Dataset. *Applied Sciences* 2024, Vol. 14, Page 4839, 14(11), 4839. <https://doi.org/10.3390/APP14114839>
- Munkhbat, B., Tsedev-ish, O., & Myagmarsuren, A. (2022). Population projection until 2050 using scenarios with maintained population growth in Ulaanbaatar and increased settlement in soums with development potential. *Mongolian Journal of Geography and Geoecology*, 43, 43–55. <https://doi.org/10.5564/MJGG.V59I43.2511>
- Naddaf-Sh, A.-M., Baburao, V. S., Zargarzadeh, H., & Drayer, P. M. (2024). Automated Weld Defect Detection in Industrial Ultrasonic B-Scan Images Using Deep Learning. *NDT* 2024, Vol. 2, Pages 108-127, 2(2), 108–127. <https://doi.org/10.3390/NDT2020007>
- Nevavuori, P., Narra, N., & Lipping, T. (2019). Crop yield prediction with deep convolutional neural networks. *Computers and Electronics in Agriculture*, 163, 104859. <https://doi.org/10.1016/J.COMPAG.2019.104859>

- Niu, W., Lei, X., Li, H., Wu, H., Hu, F., Wen, X., Zheng, D., & Song, H. (2024). YOLOv8-ECFS: A lightweight model for weed species detection in soybean fields. *Crop Protection*, 184, 106847. <https://doi.org/10.1016/j.cropro.2024.106847>
- Oerke, E. C. (2006). Crop losses to pests. *The Journal of Agricultural Science*, 144(1), 31–43. <https://doi.org/10.1017/S0021859605005708>
- Padilla, R., Netto, S. L., & Da Silva, E. A. B. (2020). A Survey on Performance Metrics for Object-Detection Algorithms. *International Conference on Systems, Signals, and Image Processing, 2020-July*, 237–242. <https://doi.org/10.1109/IWSSIP48289.2020.9145130>
- Padilla, R., Netto, S. L., & da Silva, E. A. B. (2020). A Survey on Performance Metrics for Object-Detection Algorithms. *2020 International Conference on Systems, Signals and Image Processing (IWSSIP)*, 237–242. <https://doi.org/10.1109/IWSSIP48289.2020.9145130>
- Padilla, R., Passos, W. L., Dias, T. L. B., Netto, S. L., & Da Silva, E. A. B. (2021). A Comparative Analysis of Object Detection Metrics with a Companion Open-Source Toolkit. *Electronics* 2021, Vol. 10, Page 279, 10(3), 279. <https://doi.org/10.3390/ELECTRONICS10030279>
- Price, T. (2022). Ecology of a Changed World. *Ecology of a Changed World*. <https://doi.org/10.1093/OSO/9780197564172.001.0001>
- Rattan, L. (2016). Feeding 11 billion on 0.5 billion hectare of area under cereal crops. *Food and Energy Security*, 5(4), 239–251. <https://doi.org/10.1002/FES3.99>
- Redmon, J., Divvala, S., Girshick, R., & Farhadi, A. (2016). You Only Look Once: Unified, Real-Time Object Detection. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition.*, 779–788. <http://pjreddie.com/yolo/>
- Saini, G., Khamparia, A., & Luhach, A. K. (2020). Classification of Plants Using Convolutional Neural Network. *Advances in Intelligent Systems and Computing*, 1045, 551–561. https://doi.org/10.1007/978-981-15-0029-9_44

- Servicio Nacional de Meteorología e Hidrología del Perú (SENAMHI). (2024). *Datos Hidrometeorológicos*.
<https://www.senamhi.gob.pe/main.php?dp=amazonas&p=estaciones>
- Shan, C., Gong, S., & McOwan, P. W. (2009). Facial expression recognition based on Local Binary Patterns: A comprehensive study. *Image and Vision Computing*, 27(6), 803–816.
<https://doi.org/10.1016/J.IMAVIS.2008.08.005>
- Sharma, A., Kumar, V., & Longchamps, L. (2024). Comparative performance of YOLOv8, YOLOv9, YOLOv10, YOLOv11 and Faster R-CNN models for detection of multiple weed species. *Smart Agricultural Technology*, 9, 100648.
<https://doi.org/10.1016/J.ATECH.2024.100648>
- Singh, S. R., Sakya, G., Malik, M., & Grover, C. (2025). Automated Weed Detection Using YOLOv8: A Deep Learning Approach for Indian Agriculture. *International Conference on Signal Processing and Communication, ICSC, 2025*, 289–294.
<https://doi.org/10.1109/ICSC64553.2025.10967853>
- Soltani, N., Dille, J. A., Burke, I. C., Everman, W. J., Vangessel, M. J., Davis, V. M., & Sikkema, P. H. (2016). Potential corn yield losses from weeds in North America. *Weed Technology*, 30(4), 979–984. <https://doi.org/10.1614/WT-D-16-00046.1>
- Sunil, G., Saidul Md, B., Zhang, Y., Reed, D., Ahsan, M., Berg, E., & Sun, X. (2021). Using Deep Learning Neural Network in Artificial Intelligence Technology to Classify Beef Cuts. *Frontiers in Sensors*, 2, 654357. <https://doi.org/10.3389/FSSENS.2021.654357>
- Tufail, M., Iqbal, J., Tiwana, M. I., Alam, M. S., Khan, Z. A., & Khan, M. T. (2021). Identification of Tobacco Crop Based on Machine Learning for a Precision Agricultural Sprayer. *IEEE Access*, 9, 23814–23825.
<https://doi.org/10.1109/ACCESS.2021.3056577>
- Tursun, N., Datta, A., Sakinmaz, M. S., Kantarci, Z., Knezevic, S. Z., & Chauhan, B. S. (2016). The critical period for weed control in three corn (*Zea mays* L.) types. *Crop Protection*, 90, 59–65. <https://doi.org/10.1016/J.CROPRO.2016.08.019>

- Ubaidillah, A., Rochman, E. M. S., Fatah, D. A., & Rachmad, A. (2022). Classification of Corn Diseases using Random Forest, Neural Network, and Naive Bayes Methods. *Journal of Physics: Conference Series*, 2406(1), 012023. <https://doi.org/10.1088/1742-6596/2406/1/012023>
- Ultralytics. (2024, September 27). *YOLO11*. <https://docs.ultralytics.com/es/models/yolo11/>
- Ultralytics. (2025). *Ultralytics YOLOv5*. <https://docs.ultralytics.com/es/models/yolov5/#overview>
- Venkataraju, A., Arumugam, D., Stepan, C., Kiran, R., & Peters, T. (2023). A review of machine learning techniques for identifying weeds in corn. *Smart Agricultural Technology*, 3, 100102. <https://doi.org/10.1016/J.ATECH.2022.100102>
- Veramendi Chiuyari, W., & Cruvinel, P. E. (2021). Algorithm for the Countering Maize Plants Based on UAV, Digital Image Processing and Semantic Modeling. *Proceedings - 2021 IEEE 15th International Conference on Semantic Computing, ICSC 2021*, 393–397. <https://doi.org/10.1109/ICSC50631.2021.00072>
- Wang, D., Tan, J., Wang, H., Kong, L., Zhang, C., Pan, D., Li, T., & Liu, J. (2025). SDS-YOLO: An improved vibratory position detection algorithm based on YOLOv11. *Measurement*, 244, 116518. <https://doi.org/10.1016/J.MEASUREMENT.2024.116518>
- Wei, W., Huang, Y., Zheng, J., Rao, Y., Wei, Y., Tan, X., & OuYang, H. (2025). YOLOv11-based multi-task learning for enhanced bone fracture detection and classification in X-ray images. *Journal of Radiation Research and Applied Sciences*, 18(1), 101309. <https://doi.org/10.1016/J.JRRAS.2025.101309>
- Wu, Z., Jiang, Y., Li, X., & Chung, K. L. (2024). Enhancing Precision Agriculture: YOLOv8 for Accurate Corn Disease and Pest Detection. *2024 IEEE 7th International Conference on Electronic Information and Communication Technology, ICEICT 2024*, 980–984. <https://doi.org/10.1109/ICEICT61637.2024.10671002>
- Yang, L., Zhiyuan, B., & Jiangtao, Q. (2022). Seedling maize counting method in complex backgrounds based on YOLOV5 and Kalman filter tracking algorithm. *Frontiers in Plant Science*, 13, 1030962. <https://doi.org/10.3389/FPLS.2022.1030962/BIBTEX>

- Yong-Yang, M., Zhan-Li, S., Zhigang, Z., & Kin-Man, L. (2022). Corn-Plant Counting Using Scare-Aware Feature and Channel Interdependence. *IEEE Geoscience and Remote Sensing Letters*, 19, 1–5. <https://doi.org/10.1109/LGRS.2021.3049489>
- Young, S. L., & Giles, D. K. (2014). Targeted and Microdose Chemical Applications. *Automation: The Future of Weed Control in Cropping Systems*, 139–147. https://doi.org/10.1007/978-94-007-7512-1_8
- Yu, J., Sharpe, S. M., Schumann, A. W., & Boyd, N. S. (2019). Deep learning for image-based weed detection in turfgrass. *European Journal of Agronomy*, 104, 78–84. <https://doi.org/10.1016/j.eja.2019.01.004>
- Zhang, Y., Zhang, H., Huang, Q., Han, Y., & Zhao, M. (2024). DsP-YOLO: An anchor-free network with DsPAN for small object detection of multiscale defects. *Expert Systems with Applications*, 241, 122669. <https://doi.org/10.1016/J.ESWA.2023.122669>